

Aprendizado de máquina aplicado ao ORCA-AI

Relatório de consolidação | Universidade Federal de Goiás (UFG)

Disciplina: Aprendizado de máquina aplicado a dados estruturados. Professor: Ronaldo. Autor: engenheiro Luis Fernando. Universidade Federal de Goiás (UFG). Vitória, Espírito Santo. Resultados executados em 27/09/2026; edição para entrega em 28/09/2026.

Tema: previsão de custos, classificação de famílias técnicas e descoberta de perfis de recursos em pintura e acabamentos. Fontes: SINAPI-ES e DER-ES/IOPES, analisadas separadamente. Regime: sem desoneração. Catálogo de referência: maio/2026.

Resumo executivo

SINAPI-ES: 514 serviços no catálogo. O recorte abrange pintura, pisos e revestimentos/forros. A regressão superou o último preço em 0 de 3 nichos. Árvore de decisão obteve F1 macro 0,791 em 102 serviços de teste; K-Means selecionou 3 grupos.

DER-ES / IOPES: 70 serviços no catálogo. O recorte abrange pintura, pisos e revestimentos/forros. A regressão superou o último preço em 0 de 3 nichos. Árvore de decisão obteve F1 macro 0,562 em 14 serviços de teste; nenhum k atendeu aos critérios; o agrupamento é somente diagnóstico.

As três tarefas respondem a perguntas diferentes. Seus indicadores não formam uma nota única nem um ranking entre as tabelas oficiais. O experimento apoia conferência e estudo acadêmico; a equivalência técnica dos serviços continua dependente de revisão de engenharia.

Tarefa	Pergunta	Saída
Regressão	Qual o custo da próxima competência?	Valor em R\$/m² e erro
Classificação	A qual nicho pertence a composição?	Classe sugerida e matriz de erros
Agrupamento	Quais serviços têm perfis de recursos semelhantes?	Grupos exploratórios e seus perfis

[Abrir o desenvolvimento no GitHub - versão avaliada](#)

Guia de leitura e acesso ao desenvolvimento

Este PDF reúne as três tarefas solicitadas: previsão por regressão, classificação supervisionada e agrupamento não supervisionado. Os títulos azuis de links são clicáveis e abrem o código ou a evidência correspondente no GitHub.

Roteiro de leitura: dados e método (seções 1 e 2); regressão e exemplo de pintura (3 e 4); classificação e matrizes de confusão (5 e 6); agrupamento e perfis (7 e 8); discussão conjunta (9); reprodução e referências (10). Os apêndices organizam os arquivos de cada fonte.

Versão experimental fixada: commit `e20741b0214dff489147fa04739bb2a1ed44bc07`. Os links preservam essa versão do código e dos resultados, mesmo que a branch main receba melhorias. Esta edição acrescenta navegação e identificação acadêmica; as métricas vêm da execução já concluída.

Acesso público: em 28/09/2026, o proprietário autorizou tornar o repositório público para consulta. Os links permitem ler e baixar os arquivos sem convite ou login. A escrita no repositório permanece restrita às contas autorizadas. O PDF contém os resultados e gráficos para leitura independente.


Para começar pelo código, abra `executar_estudo.py`. Esse arquivo executa as três tarefas no mesmo recorte temático. Os scripts individuais e os módulos especializados estão ligados nas seções de resultados. CSV é uma tabela de dados que pode ser baixada e aberta no Excel, no VS Code ou em Python.

1. [Código principal - executar_estudo.py](#)
2. [Guia de instalação e execução no VS Code](#)
3. [Resultados completos das duas fontes](#)
4. [Manifesto da execução: parâmetros, versões e hashes](#)
5. [Plano do experimento e critérios de avaliação](#)

1. Dados, recorte e unidades de observação

Foram usados os mesmos três nichos e apenas serviços em m². Classificação e agrupamento utilizam uma composição por serviço em maio/2026. A regressão usa o histórico e avalia pares serviço-competência entre março e maio/2026; portanto, sua quantidade de previsões é maior que a quantidade de serviços.

A interseção abaixo torna explícitos os serviços presentes em ambas as análises. Não foram removidos retrospectivamente serviços que deixaram de existir no catálogo de maio. A distribuição reflete os catálogos, não a frequência desses serviços em obras.



Fonte	Catálogo	Variantes	Em ambas	Só catálogo	Só regressão
SINAPI-ES	514	110	514	0	4
DER-ES / IOPES	70	52	60	10	0

SINAPI-ES - dataset do recorte, 514 serviços

DER-ES/IOPES - dataset do recorte, 70 serviços

Código de preparação dos atributos e dos grupos de variantes

2. Método e controles do experimento

As classes pintura, pisos e revestimentos/forros derivam do mapeamento dos grupos oficiais. Não representam rótulos homologados por revisão humana. Os serviços foram unidos em grupos de variantes quando têm os mesmos recursos-folha ou descrições normalizadas semelhantes; esse procedimento reduz vazamento, mas não garante independência técnica completa.

Regressão: LinearRegression simples (último custo) e múltipla (três custos consecutivos); seleção por erro quadrático na validação e comparação com a persistência, que repete o último preço. Teste cronológico de março a maio/2026. Cada previsão olha apenas uma competência à frente, incorporando preços anteriores disponíveis. O estudo é retrospectivo, com histórico revisado.

A validação nominal da regressão é janeiro-fevereiro/2026. No SINAPI, o controle de publicação deixa apenas janeiro efetivamente avaliável: as revisões de janeiro e fevereiro foram publicadas em 25/03/2026, quando o alvo de fevereiro já era conhecido. No DER, janeiro e fevereiro são usados; faltam datas reais de publicação e a interpretação é retrospectiva.

Classificação: Random Forest, árvore de decisão e KNN. O primeiro dos cinco folds estratificados por grupos forma o teste; três folds internos escolhem parâmetros por F1 macro. A referência é prever a classe mais frequente. Escalonamento e modelos são ajustados dentro de cada treino. Código, descrição e grupo oficial do serviço ficam fora das dez entradas [3, 4].

Agrupamento: K-Means com escala própria por fonte, 30 inicializações, semente 42 e k entre 2 e 5. Seleção pela maior silhouette entre candidatos cujo menor grupo tem ao menos max(3, teto de 5% do catálogo). Classes não entram no ajuste. A estabilidade é reavaliada com outras sementes e subamostras de 80% [5].

Extração: subcomposições são expandidas até recursos-folha. No SINAPI, o total hierárquico concilia exatamente após truncar cada parcela a centavos em cada nível. As participações de recursos usam a soma sem truncamento e são aproximações. Preços SP usados na ausência de ES ficam identificados. O DER incorpora encargos à mão de obra; o SINAPI discrimina diversos encargos complementares, impedindo comparar suas contagens como se fossem equivalentes.


Entradas de classificação e agrupamento		Unidade
4 participações de custo: mão de obra, material, equipamento, outros		Fração de 0 a 1
4 contagens de recursos distintos nas mesmas categorias		Recursos por composição
Horas de mão de obra e equipamento extraídas das folhas em H		h/m²
Indicador		Leitura didática
MAPE		Média do erro absoluto em %, menor é melhor.
F1 macro		Equilibra precisão e recall, dando o mesmo peso às três classes.
Silhouette		Coesão e separação dos grupos, de -1 a 1; maior favorece separação.
ARI de estabilidade		Concordância entre agrupamentos após reajuste; 1 indica igualdade.

3. Regressão: previsões comparadas ao último preço

O gráfico compara o erro médio percentual da regressão selecionada na validação com a previsão simples do último preço. n conta previsões serviço-competência. Cada observação tem o mesmo peso; estes números não medem economia financeira de uma obra.

Recortes nativos sem amostra suficiente permanecem explicitamente fora da regressão; o resultado parcial do DER não foi preenchido com estimativas inventadas. A cobertura por serviço está na tabela de populações e os motivos constam em regressao/resumo.json.

Erros pequenos podem coexistir com desempenho inferior ao último preço. A mediana descreve o erro típico e reduz a influência de casos extremos. MAE, RMSE e MSE por grupo nativo estão preservados nos arquivos técnicos. O limite de 5% usado em análises auxiliares é didático, sem caráter de tolerância oficial [4].



Regressão | interpretação das estatísticas

A tabela reúne os mesmos valores do gráfico e acrescenta a mediana. $MAPE = \text{média de } 100 \times |\text{previsto} - \text{publicado}| / \text{publicado}$. A referência último preço é calculada nas mesmas observações, permitindo uma comparação pareada.

Exemplo de interpretação: um erro de 1,32% significa que a distância percentual absoluta entre estimativa e custo publicado foi, em média, 1,32%. Não significa probabilidade de acerto, aumento do preço, economia contratual nem precisão garantida para um serviço novo.

A mediana divide as observações em duas metades: metade dos erros é menor ou igual a ela. Quando a média supera muito a mediana, alguns erros maiores estão influenciando a média. Os CSVs `estatisticas_nichos.csv` e `estatisticas_recortes.csv` conservam P90, dispersão e indicadores complementares.

Comparação do MAPE por fonte: SINAPI-ES: regressão superior ao último preço em 0 de 3 nichos; DER-ES / IOPEs: regressão superior ao último preço em 0 de 3 nichos. Os resultados sustentam manter a referência simples na avaliação e estudar novos atributos e horizontes em experimentos futuros.

Fonte	Nicho	n	MAPE modelo	Último preço	Mediana
SINAPI-ES	Pintura	371	1,32%	0,42%	1,33%
SINAPI-ES	Pisos	205	1,22%	1,01%	0,83%
SINAPI-ES	Revestimentos e forros	918	1,26%	1,17%	0,97%
DER-ES / IOPEs	Pintura	81	2,74%	2,51%	2,02%
DER-ES / IOPEs	Pisos	69	1,59%	1,47%	0,78%
DER-ES / IOPEs	Revestimentos e forros	30	1,96%	1,47%	0,79%

[Código Python - modelos lineares, teste temporal e persistência](#)

[SINAPI-ES - estatísticas por nicho da regressão](#)


[DER-ES/IOPEs - estatísticas por nicho da regressão](#)

4. Pintura em detalhe | SINAPI-ES

Exemplo 96130: APLICAÇÃO MANUAL DE MASSA ACRÍLICA EM PAREDES EXTERNAS DE CASAS, UMA DEMÃO. AF_03/2024

O código foi escolhido para continuidade com a apresentação de regressão, sem selecionar pelo acerto. Os exemplos de SINAPI e DER ilustram seus próprios catálogos e não foram homologados como serviços tecnicamente equivalentes.

Este serviço pertence ao treino da classificação; nenhuma previsão de teste foi inventada para ele. No agrupamento, aparece no grupo 1 do K-Means selecionado.



Competência	Publicado	Regressão	Último preço
2026-03	25,84	25,51	25,68
2026-04	25,65	26,07	25,84
2026-05	25,65	26,13	25,65


Competência	Publicado R\$/m²	Regressão R\$/m²	Último R\$/m²	Erro modelo %
2026-03	25,84	25,51	25,68	1,26
2026-04	25,65	26,07	25,84	1,65
2026-05	25,65	26,13	25,65	1,86

4. Pintura em detalhe | DER-ES / IOPES

Exemplo 190115: Pintura, sobre paredes e forros, aplicação manual, com duas demãos de tinta látex PVA premium, referência Suvinil, Coral e Metalatex, inclusive uma demão de líquido selador PVA, referência Suvinil, Coral ou Metalatex ou equivalente

O código foi escolhido para continuidade com a apresentação de regressão, sem selecionar pelo acerto. Os exemplos de SINAPI e DER ilustram seus próprios catálogos e não foram homologados como serviços tecnicamente equivalentes.

Este serviço pertence ao treino da classificação; nenhuma previsão de teste foi inventada para ele. No agrupamento, aparece no grupo 0 do diagnóstico, sem candidato aceito.




Competência	Publicado	Regressão	Último preço
2026-03	25,00	25,23	25,00
2026-04	23,87	25,23	25,00
2026-05	25,15	24,09	23,87

Competência	Publicado R\$/m²	Regressão R\$/m²	Último R\$/m²	Erro modelo %
2026-03	25,00	25,23	25,00	0,91
2026-04	23,87	25,23	25,00	5,69
2026-05	25,15	24,09	23,87	4,22

5. Classificação: seleção independente do teste

As barras azuis mostram a média de F1 macro na validação para o melhor candidato de cada algoritmo; os traços representam o desvio entre três folds, não um intervalo de confiança. As barras laranja mostram o teste reservado. A classe majoritária é a referência e não participou da seleção.

Um algoritmo pode obter resultado maior no teste e ainda assim não ser o selecionado. A escolha continua baseada na validação, evitando selecionar retrospectivamente o modelo que mais acertou o teste. F1 macro tem escala de 0 a 1 e não deve ser apresentado como porcentagem de serviços corretamente classificados.



[Código Python - classificação, validação e escolha do modelo](#)


[Executar somente a classificação - executar_classificacao.py](#)

6. Matriz de confusão | SINAPI-ES

Modelo selecionado: Árvore de decisão. Treino: 412 serviços em 89 grupos de variantes. Teste: 102 serviços em 21 grupos. F1 macro = 0,791; acurácia balanceada = 0,831; acurácia = 81,4%.

Leia cada linha como a classe real. A diagonal contém acertos; as outras células mostram para qual classe os serviços foram confundidos. O percentual dentro de cada célula usa o total da própria linha. Precisão pergunta se as sugestões da classe acertaram; recall pergunta quantos serviços reais da classe foram reconhecidos.

SINAPI-ES | onde a classificação acertou? Árvore de decisão | 102 serviços de teste



Classe	n teste	Precisão	Recall	F1
Pintura	24	0,821	0,958	0,885
Pisos	17	0,565	0,765	0,650
Revestimentos e forros	61	0,922	0,770	0,839

[Métricas de teste dos classificadores](#)

[Previsões por serviço para conferir acertos e erros](#)


[Partições de treino e teste, com os grupos de variantes](#)

6. Matriz de confusão | DER-ES / IOPES

Modelo selecionado: Árvore de decisão. Treino: 56 serviços em 43 grupos de variantes. Teste: 14 serviços em 9 grupos. F1 macro = 0,562; acurácia balanceada = 0,567; acurácia = 57,1%.

Leia cada linha como a classe real. A diagonal contém acertos; as outras células mostram para qual classe os serviços foram confundidos. O percentual dentro de cada célula usa o total da própria linha. Precisão pergunta se as sugestões da classe acertaram; recall pergunta quantos serviços reais da classe foram reconhecidos.

DER-ES / IOPES | onde a classificação acertou? Árvore de decisão | 14 serviços de teste



Classe	n teste	Precisão	Recall	F1
Pintura	5	0,500	0,800	0,615
Pisos	4	0,667	0,500	0,571
Revestimentos e forros	5	0,667	0,400	0,500

Métricas de teste dos classificadores

Previsões por serviço para conferir acertos e erros


Partições de treino e teste, com os grupos de variantes

7. Agrupamento | SINAPI-ES

Foi selecionado $k=3$, com silhouette 0,388, entre os candidatos elegíveis. Cada grupo precisava de ao menos 26 serviços.

Silhouette maior só torna um candidato preferível quando os demais critérios também são atendidos. Davies-Bouldin favorece valores menores; Calinski-Harabasz favorece valores maiores dentro deste mesmo conjunto. A estabilidade por grupos de variantes é a verificação mais conservadora quando variantes semelhantes estão presentes.

A média e o mínimo do ARI são apresentados juntos: uma mediana elevada pode esconder uma reamostragem instável. A estabilidade descreve reajustes no catálogo; não mede desempenho preditivo em uma obra nova.



k	Elegível	Silhouette	Davies-Bouldin	Calinski-H.
2	sim	0,368	1,297	232,2
3	sim	0,388	1,071	203,2
4	sim	0,362	1,002	219,1
5	não	0,372	0,899	221,3

Reajuste	ARI médio	ARI mínimo
Outras sementes	1,000	1,000
80% dos serviços	1,000	1,000
80% dos grupos de variantes	0,906	0,514



Código Python - K-Means, seleção de k e estabilidade

Tabela de candidatos a k e critérios de elegibilidade

8. Perfis de recursos | SINAPI-ES

A projeção PCA mostra 59,9% da variância em duas dimensões. O K-Means calcula distâncias nos dez atributos padronizados, não apenas neste desenho. Os números dos grupos são identificadores arbitrários, sem correspondência automática com os grupos da outra base.

As barras mostram a média das participações aproximadas de recursos de cada grupo. Horas de equipamento iguais a zero significam ausência de folhas mensuradas em H, não ausência de equipamento: aquisições podem estar representadas em outras unidades.




7. Agrupamento | DER-ES / IOPES

Nenhum k foi aceito. O menor k calculável, 2, é apresentado apenas como diagnóstico. O critério mínimo era 4 serviços no menor grupo; esse critério não foi alterado após observar os dados.

Silhouette maior só torna um candidato preferível quando os demais critérios também são atendidos. Davies-Bouldin favorece valores menores; Calinski-Harabasz favorece valores maiores dentro deste mesmo conjunto. A estabilidade por grupos de variantes é a verificação mais conservadora quando variantes semelhantes estão presentes.

A média e o mínimo do ARI são apresentados juntos: uma mediana elevada pode esconder uma reamostragem instável. A estabilidade descreve reajustes no catálogo; não mede desempenho preditivo em uma obra nova.

DER-ES / IOPES | seleção do número de grupos diagnóstico, sem k aceito | n=70 serviços



k	Elegível	Silhouette	Davies-Bouldin	Calinski-H.
2	não	0,671	0,609	33,3
3	não	0,394	0,969	39,9
4	não	0,404	0,760	44,0
5	não	0,323	0,904	41,8

Reajuste	ARI médio	ARI mínimo
Outras sementes	1,000	1,000
80% dos serviços	1,000	1,000
80% dos grupos de variantes	0,953	0,055

[Código Python - K-Means, seleção de k e estabilidade](#)


[Tabela de candidatos a k e critérios de elegibilidade](#)

8. Perfis de recursos | DER-ES / IOPES


A projeção PCA mostra 72,2% da variância em duas dimensões. O K-Means calcula distâncias nos dez atributos padronizados, não apenas neste desenho. Todos os perfis abaixo são diagnósticos; nenhum agrupamento foi aceito.

As barras mostram a média das participações aproximadas de recursos de cada grupo. Horas de equipamento iguais a zero significam ausência de folhas mensuradas em H, não ausência de equipamento: aquisições podem estar representadas em outras unidades.

DER-ES / IOPES | mapa dos perfis de recursos diagnóstico, sem k aceito | k=2; cada ponto = um serviço



**DER-ES / IOPES | perfil médio de cada grupo
Custo dos recursos (%) | diagnóstico, sem k aceito**



9. Consolidação, discussão e conclusão

SINAPI-ES: o classificador selecionado obteve F1 macro 0,791, frente a 0,249 da classe majoritária. O agrupamento possui candidato elegível, sujeito à revisão dos perfis.

DER-ES / IOPEs: o classificador selecionado obteve F1 macro 0,562, frente a 0,175 da classe majoritária. O agrupamento não passou pelos critérios; revisar atributos e tratamento dos poucos perfis raros é uma evolução futura, que exige novo experimento.

A contribuição ao ORCA-AI é oferecer três recursos complementares: cenários de custo com referência simples, sugestão de classe para composições estruturadas e exploração de perfis. Um agrupamento não comprova substituição técnica de serviços; uma sugestão de classe exige conferência antes do uso profissional.

Limitações: catálogo pequeno no DER, classes derivadas e não homologadas, dependência residual entre variantes, história revisada, participação de preços SP no SINAPI e diferentes convenções de encargos. A comparação é descritiva em cada fonte. Não foram estimados intervalos de confiança tratando observações dependentes como independentes.

As três tarefas do enunciado foram executadas e seus resultados preservados, incluindo resultados desfavoráveis. Aprendizado por reforço permanece fora do escopo. A continuidade recomendada é revisar os rótulos e os perfis raros, testar em novas composições e ampliar a avaliação temporal sem reutilizar este teste para decisões de ajuste.

Aspecto	Regressão	Classificação	Agrupamento
Unidade	Serviço-mês	Serviço de maio	Serviço de maio
Supervisão	Custo conhecido como alvo	Nicho como rótulo	Sem rótulo no ajuste
Modelo	Linear simples/múltipla	RF, árvore e KNN	K-Means
Referência	Último preço	Classe majoritária	Critério de tamanho e estabilidade
Indicador	MAPE, MAE, RMSE, MSE	F1 macro e matriz de erros	Silhouette, DB, CH e ARI
Decisão apoiada	Planejamento do próximo custo	Conferência da família técnica	Exploração de perfis semelhantes

10. Reprodução e referências

No VS Code, abra a pasta OrcaAI/ml, selecione o Python de .venv e execute executar_estudo.py. Para recriar somente a apresentação, utilize gerar_relatorio_estudo.py com a pasta da execução concluída. O relatório não treina modelos. Cada nova execução usa uma pasta nova para preservar resultados anteriores.

Os CSVs de dados, previsões, partições, matrizes, centroides, projeções e métricas ficam nas pastas de cada fonte. execucao_estudo.json registra parâmetros e hashes do código; manifesto_relatorio.json registra os hashes dos arquivos efetivamente usados nesta apresentação. As sementes e versões de Python/scikit-learn estão nos resumos das tarefas.

SINAPI-ES: ZIP SHA-256

928df42a952625eb12d41baf2b5ab17e1207af6e7881cb9f1c7fcac4708400e3. Serviços com preço SP: 54. Diferença máxima entre soma das folhas sem truncamento e custo publicado: 0,7811%.

DER-ES / IOPEs: ZIP SHA-256

9d7efd575c10dc676bc49f5acb5630fa9b3cd2b98449be07612e1891e8d213f6. Serviços com preço SP: 0. Diferença máxima entre soma das folhas sem truncamento e custo publicado: 0,4576%.

Materiais da disciplina: OrcaAI/spec/ml_ufg/mapa_materiais_disciplina.md identifica as aulas e exemplos que fundamentaram a escolha de LinearRegression, Random Forest, árvore, KNN e K-Means. O código, os dados derivados e as tabelas de auditoria acompanham esta entrega.

[1] CAIXA - SINAPI: tabelas e documentação oficial

[2] DER-ES - referencial de preços de edificações

[3] scikit-learn - divisão estratificada por grupos

[4] scikit-learn - métricas de avaliação

[5] scikit-learn - agrupamento e seus indicadores

Apêndice A. Como executar e conferir o trabalho

1. Baixe a versão pública fixada ou clone o projeto. Para reproduzir exatamente a versão avaliada, use git checkout e20741b0214dff489147fa04739bb2a1ed44bc07. No VS Code, abra a pasta OrcaAI/ml.
2. Use Python 3.12. Crie o ambiente com `python3.12 -m venv .venv`; ative-o com `source .venv/bin/activate` (macOS/Linux) ou `.venv\Scripts\Activate.ps1` (PowerShell). Instale as dependências com `python -m pip install -r requirements.txt`.
3. Execute `python executar_estudo.py`. O programa lê os ZIPs e datasets incluídos no projeto, processa as fontes separadamente e cria uma nova pasta de resultados. Esse comando refaz as três tarefas no recorte de pintura, pisos e revestimentos/forros; preserve a estrutura do repositório.
4. Para executar uma única tarefa, use `python executar_classificacao.py` ou `python executar_agrupamento.py`. O script `executar_regressao.py` preserva a avaliação original mais ampla; o recorte comum das três tarefas é executado por `executar_estudo.py`.
5. Para conferir a implementação, instale `python -m pip install -r requirements-dev.txt` e rode `python -m pytest -q`. A versão experimental publicada passou por 221 testes e nove subtestes. Cada teste automatizado verifica uma regra do programa; isso não equivale a validação profissional dos modelos.

Arquivos CSV grandes podem não ter prévia no GitHub. Use Download raw file ou baixe o repositório para ler os dados completos. Os links dos apêndices priorizam as tabelas compactas do recorte. O mapa das aulas descreve os materiais consultados; arquivos originais externos da disciplina não fazem parte deste repositório.

[Executar as três tarefas no recorte - executar_estudo.py](#)

[Executar a regressão original - executar_regressao.py](#)

[Executar a classificação - executar_classificacao.py](#)

[Executar o agrupamento - executar_agrupamento.py](#)

[Dependências e versões - requirements.txt](#)

[Testes automatizados das rotinas](#)

[Preparação de dados - preparar_dados.py](#)

[Leitor e conciliação das composições SINAPI](#)

[Leitor e conciliação das composições DER-ES](#)

[Mapa dos conteúdos da disciplina usados no projeto](#)

Apêndice B. Evidências por fonte | SINAPI-ES

Este índice permite seguir cada conclusão até a tabela que a originou. Código e descrição identificam serviços dentro da própria fonte; os códigos SINAPI e DER não são pares de equivalência técnica.

Na classificação, compare a validação, que escolhe o algoritmo, com o teste reservado, que mede o resultado final. No agrupamento DER, preserve a indicação de diagnóstico: nenhum candidato cumpriu o tamanho mínimo de grupo.

Dataset: atributos e classes de cada serviço

Recursos extraídos das composições analíticas

Auditoria da extração e conciliação dos custos

Populações: serviços presentes em cada tarefa

Regressão: publicado, previsto e persistência por observação

Regressão: estatísticas agregadas por nicho

Classificação: métricas da validação usada na seleção

Classificação: matriz de confusão em formato de tabela

Classificação: parâmetros, versões e resumo

Agrupamento: grupo atribuído a cada serviço

Agrupamento: médias dos atributos de cada grupo

Agrupamento: resultados das verificações de estabilidade

Agrupamento: seleção, diagnóstico e resumo

Todas as tabelas e modelos desta fonte

Apêndice B. Evidências por fonte | DER-ES / IOPES

Este índice permite seguir cada conclusão até a tabela que a originou. Código e descrição identificam serviços dentro da própria fonte; os códigos SINAPI e DER não são pares de equivalência técnica.

Na classificação, compare a validação, que escolhe o algoritmo, com o teste reservado, que mede o resultado final. No agrupamento DER, preserve a indicação de diagnóstico: nenhum candidato cumpriu o tamanho mínimo de grupo.

Dataset: atributos e classes de cada serviço

Recursos extraídos das composições analíticas

Auditoria da extração e conciliação dos custos

Populações: serviços presentes em cada tarefa

Regressão: publicado, previsto e persistência por observação

Regressão: estatísticas agregadas por nicho

Classificação: métricas da validação usada na seleção

Classificação: matriz de confusão em formato de tabela

Classificação: parâmetros, versões e resumo

Agrupamento: grupo atribuído a cada serviço

Agrupamento: médias dos atributos de cada grupo

Agrupamento: resultados das verificações de estabilidade

Agrupamento: seleção, diagnóstico e resumo

Todas as tabelas e modelos desta fonte